

超越症状简单相加： 胃食管反流病的二维概率诊断工具

Tong-Yun HAO, Wei-Wu WANG

2026年8月

摘要

胃食管反流病（GERD）症状问卷通常将症状频率和强度转换为等级分值后直接相加。这种方法虽然方便，却隐含了若干通常未经验证的假设：相邻等级之间的距离相等；一个单位的频率可与一个单位的强度互换；症状效应呈线性；频率与强度之间不存在交互；同一个阈值可以直接用于不同人群。本文提出一种用于替代算术总分的理论工具——二维反流概率工具（Bivariate Reflux Probability Instrument, BRPI）。BRPI将频率与强度保留为不同维度，目标是估计存在客观证据支持、可采取临床行动的GERD概率。推荐结构包括两层：首先采用二维分级反应测量模型，在考虑患者报告不确定性的同时估计潜在频率和强度；随后采用具有单调约束的贝叶斯广义相加模型，学习不同症状的非线性风险曲面及交互作用。烧心和反流是核心指标；夜间症状和睡眠干扰可提供增量信息；上腹痛和恶心可作为鉴别诊断特征。报警症状不参与数值抵消，而是直接进入临床评估路径。工具输出不是总分，而是经过校准并带有不确定区间的概率，以及低概率、不确定和高概率三个行动区域。模型系数和阈值必须在前瞻性研究中，以现代内镜和反流监测标准为参照进行估计，并完成内部、时间、地域和临床影响验证。示意性概率曲线说明，相同的简单总分可能代表不同风险。模糊隶属函数可改善患者作答界面，但模糊规则不能替代以临床结局为基础的概率校准。BRPI拟替代症状分诊中的粗糙加法，而不是在需要客观确诊时替代内镜或动态反流监测。

关键词：胃食管反流病；GERD；问卷；模糊逻辑；项目反应理论；贝叶斯模型；广义相加模型；诊断概率；校准；临床预测模型

1 引言

GERD是胃内容物反流引起令人困扰的症状或并发症，但患者症状、黏膜损伤、反流负荷和症状感知并不完全一致 [1-5]。烧心和反流可提高GERD的先验概率，然而类似症状也可见于反流高

敏感、功能性烧心、功能性消化不良、贲门失弛缓、反刍综合征、心脏疾病及其他情况 [6–9]。因此，现代指南将症状分诊与内镜、动态pH或pH-阻抗监测获得的客观证据区分开来 [2, 3, 6, 10, 11]。

反流病问卷 (RDQ)、GerdQ、FSSG和ReQuest等工具提高了症状评价的标准化程度 [12–18]。但是，其常见算术形式会掩盖数据结构。例如，把频率和强度分别记为0–3分后相加，只要总分相同，就会把每月一次的严重症状与多数日出现的轻微症状视为等价。该做法还假定“从无到一天”和“从四天到每天”的变化具有相同意义，并假定强度和频率相互独立。现有综合证据显示，常用症状问卷的诊断准确度总体为中等，这与测量局限及GERD生物学异质性均相符 [14, 15, 19–22]。

因此，频率与强度不应简单相加这一数学质疑是成立的。然而，解决办法不是任意换成更复杂的公式，而是建立一个以临床参照结局训练、可在目标环境中校准、能够表达不确定性并改善决策的模型。本文提出BRPI的可检验方法学框架，将心理测量、非线性概率模型和循证诊断评价结合起来。文中所有数值系数和曲线均为示意，必须通过临床研究重新估计。

2 简单总分为何不是充分的测量模型

设 F_j 和 I_j 分别表示第 j 种症状的频率和强度。传统问卷通常计算

$$S = \sum_{j=1}^J (a_j F_j + b_j I_j), \quad (1)$$

并在 $S \geq c$ 时判断为GERD。如果没有数据支持，式 (1) 实际上强制假定各等级为等距尺度、权重恒定、效应可加、不存在交互、不同环境无差异，并且疾病在 c 处存在清晰生物学边界。

频率和强度彼此相关，但不可互换。频率近似反映一段时间内反复发生或反复感知；强度同时受到单次事件幅度、内脏敏感性、中枢放大、语言和回忆方式影响。简单使用乘积 $F_j I_j$ 也不能充分解决问题：它在任一维度为零时强制负荷为零，容易放大极端值，并且仍规定了固定函数形式。合理模型应允许“罕见但严重的反流”“每天轻微烧心”以及“频繁且强烈的症状”位于风险曲面的不同区域。

硬阈值还会丢失不确定性。当测量误差较大时，概率0.49与0.51不应自动导致完全不同的处理。阳性预测值和阴性预测值也会随患病率与转诊谱改变，专科中心建立的阈值不能直接用于社区筛查 [23–27]。

3 预期用途与目标疾病

在建模之前必须锁定工具的预期用途。本文建议将BRPI用于成人基层医疗或普通门诊中，上消化道症状患者在明确诊断之前的分诊。目标结局为“可采取行动的GERD”，即具有足够客观或临床证据支持开展反流相关处理，并依据现代共识预先定义 [2, 3, 6, 7]。儿童、妊娠、既往已证实重度GERD、术后解剖改变及主要食管动力障碍需要单独验证。

报警特征不是普通计分项。吞咽困难、吞咽痛、消化道出血、贫血、非意愿性体重下降、持续呕吐、包块或令人担忧的胸痛，无论计算概率如何，均应进入安全评估路径。需要紧急心脏评价的胸部症状绝不能因反流模型而延误。

表 1: 简单加法问卷隐含的假设及BRPI的对应处理。

问题	可能后果	BRPI处理
把等级当作等距数值	等级间距由研究者强制规定	分级反应阈值, 或直接记录天数与锚定强度
频率可与强度互换	相同总分可能代表不同临床状态	保留两个维度并学习风险曲面
效应必须线性	不能表达平台、加速或阈值效应	带收缩的单调样条
忽略症状交互	烧心与反流共存的信息被遗漏	预先规定的二维张量交互
硬阈值且无不确定性	过度解释临界答案	概率区间与不确定区域
所有环境使用同一阈值	患病率和病例谱变化导致失准	环境特异截距再校准和外部验证
把症状等同于客观GERD	功能性疾病及高敏感被误分	客观参照标准及可选多分类模型

参照标准的判读者应不知道BRPI结果。根据具体临床问题, 可采用内镜、延长无线pH监测、导管pH-阻抗监测, 并在需要排除主要动力障碍时采用测压 [3, 6, 10, 11, 28–34]。明确阳性和明确阴性的条件应写入锁定方案。Barrett食管等并发症应进入既有专门路径 [35]。生理学边界结果不应被强迫二分, 可由盲法专家判定, 或作为潜在/中间类别建模。

4 建议工具的观测项目

4.1 核心症状

患者在七天观察窗内, 分别报告各核心症状的频率与强度。频率最好记录有症状的天数 (0–7天), 条件允许时同时记录发作次数。强度采用具有锚点的0–10量表: 0为无, 3为能够察觉但不影响活动, 5为干扰日常活动, 7为明显限制活动, 10为可想象的最严重程度。与单纯使用“轻、中、重”相比, 功能锚点更有利于减少语言漂移。

电子工具可采用短期症状日记, 而不是只进行一次回顾性回答。重复测量可区分“只有一次但印象深刻的严重发作”和“稳定的高症状负荷”, 并减少回忆误差。完成项目反应校准后, 可在后验不确定性已经足够小时使用自适应提问。

4.2 测量层: 二维分级反应模型

等级答案应作为有序类别处理, 而不是默认其数值距离。对于患者 n 、症状 j 、维度 $d \in \{F, I\}$ 及反应阈值 k , 分级反应模型为

$$\Pr(Y_{njd} \geq k \mid \theta_{nd}) = \text{logit}^{-1}[a_{jd}(\theta_{nd} - b_{jdk})], \quad (2)$$

表 2: BRPI候选数据项目。正式开发后应进一步缩短。

领域	测量方法	模型作用
烧心	每周天数、次数及0–10强度	核心阳性指标
酸性或液体反流	每周天数、次数及0–10强度	核心阳性指标；与烧心分开建模
夜间反流症状	每周夜数及睡眠中断	附加负荷与时间特征
餐后关系	餐后发生的比例	情境修饰变量
体位关系	平卧或弯腰相关性	情境修饰变量
上腹痛与恶心	分别记录频率和强度	鉴别诊断信息，不简单反向计分
抗酸药反应	如可观察则记录时间与变化	探索性变量；避免循环论证和回忆偏倚
用药与先验信息	PPI、年龄、BMI、既往GERD证据	校准和适用性变量
报警特征	是否存在及具体内容	安全性覆盖，不能被其他分值抵消
作答确定性	滑动条或“不确定”选项	测量不确定性或模糊界面

其中 θ_{nF} 和 θ_{nI} 是相关的潜在频率与强度， a_{jd} 为项目区分度， b_{jdk} 为按顺序排列的阈值。该方法通过数据估计等级间距。必须检验语言、性别、年龄、文化和医疗环境之间的项目功能差异 [36–44]。

如果症状天数和锚定连续强度具有良好可靠性，诊断层也可直接使用原始观测。保留IRT层特别适用于分类回答、自适应测验或需要表达患者作答不确定性的情形。双因素或多维模型可以检验是否存在共同的反流症状特质，同时保留各症状特异的频率和强度。

4.3 诊断层：单调贝叶斯广义相加模型

对于二分类“可采取行动的GERD”结局 D_n ，建议首先评价以下模型：

$$\begin{aligned} \text{logit Pr}(D_n = 1) = & \alpha_s + f_{HF}(\theta_{nF}^H) + f_{HI}(\theta_{nI}^H) + f_{RF}(\theta_{nF}^R) + f_{RI}(\theta_{nI}^R) \\ & + g_H(\theta_{nF}^H, \theta_{nI}^H) + g_R(\theta_{nF}^R, \theta_{nI}^R) + \beta^T \mathbf{x}_n, \end{aligned} \quad (3)$$

其中 H 表示烧心， R 表示反流， f 为单调平滑函数， g 为经过收缩控制的二维交互， $\mathbf{x}$ 为预先规定的修饰变量， α_s 为医疗环境特异的截距。先验分布用于限制不合理的曲线振荡和过度交互。模型输出的是概率后验分布，而不是一个确定总分 [45–50]。

对于核心症状，单调性具有临床合理性：在其他条件相同时，频率增加通常不应使GERD概率下降，除非有强证据支持非单调关系。鉴别诊断项目不应机械地反向计分，其作用可能很弱、非线性或依赖情境。完整模型必须与更简单的惩罚逻辑回归比较；只有在验证中改善校准与净获益时才保留复杂结构。

4.4 可选模糊作答层

模糊数学适合把含糊语言转换为重叠的隶属度。例如, $f \in [0, 7]$ 可同时对“罕见”“间断”和“频繁”集合具有部分隶属度。“频繁”的平滑隶属函数可表示为

$$\mu_{\text{frequent}}(f) = [1 + \exp\{-\kappa(f - \tau)\}]^{-1}. \quad (4)$$

强度也可类似处理, 因此从2天变为3天不会产生人为跳跃。Mamdani或Takagi-Sugeno系统可组合语言规则 [51–55]。

但是, “如果频率高且强度重, 则GERD可能性高”这类专家规则并不能自动获得诊断效度。隶属函数和规则后件仍需根据参照结局学习或重新校准。因此, BRPI主要将模糊方法用于作答界面和解释, 最终概率仍采用结局校准。纯模糊系统应作为比较模型, 而不是默认首选。

5 示意性概率曲线与风险曲面

为说明设计思想, 考虑以下故意简化的函数:

$$\hat{p} = \text{logit}^{-1} [-4.2 + 0.52F + 0.38I + 0.075FI], \quad (5)$$

其中 F 为每周症状天数, I 为0–10强度。上述系数不是临床估计值, 只用于展示频率会改变强度的意义, 强度也会改变频率的意义。

该示例说明, 相同加和结果不一定具有相同意义。例如, $(F, I) = (6, 2)$ 和 $(2, 6)$ 的简单总和均为8, 但由于“频繁低强度”和“少见高强度”的模式不同, 式 (5) 给出的概率不同。正式工具应分别估计烧心与反流的风险曲面, 再与其他经验证预测因素组合。

6 从概率转换为临床行动

BRPI应显示: (1) 估计概率; (2) 90%或95%不确定区间; (3) 用通俗语言说明主要影响因素; (4) 推荐下一步。三个区域比单一阈值更安全:

- **低概率:** 考虑其他诊断和保守处理, 同时保留临床判断。
- **不确定:** 重复日记测量、评估混杂因素, 或在结果能够改变处理时进行客观检查。
- **高概率:** 对于无并发症的典型表现, 可进入结构化反流处理路径; 在侵入性治疗之前或长期诊断确定性重要时, 仍需客观证据。

阈值应根据错误决策的后果选择。若漏诊的损害明显高于不必要检查, 应降低下阈值。对于阈值概率 p_t , 决策曲线净获益为

$$\text{NB}(p_t) = \frac{\text{TP}}{N} - \frac{\text{FP}}{N} \frac{p_t}{1 - p_t}. \quad (6)$$

只有当BRPI在临床相关阈值范围内优于“全部检查”“均不检查”和现有问卷时, 才具有采用价值 [56–58]。




图 1: 分别保留频率和强度的示意性概率曲线。虚线为假设行动阈值, 不是经过验证的临床界值。




图 2: 二维概率曲面示例。曲率和交互必须由数据学习; 本图是方法学设计示例, 不是诊断计算器。

7 开发研究设计

7.1 人群与参照标准

建议开展前瞻性、多中心、横断面诊断研究，在参照检查前连续纳入有症状成人。应明确覆盖基层医疗、普通消化门诊和食管生理转诊中心。患者在不知道概率结果的情况下完成电子日记，参照检查判读者对问卷结果设盲。

参照方案依据现代内镜及反流监测标准，预先定义GERD证据充分、反对GERD和证据不确定三类 [2,3,6,10,29]。如果只有高分患者接受监测，会产生验证偏倚。因此，应尽可能使所有患者接受适当参照评价，或通过抽样权重和敏感性分析处理部分验证。PPI治疗状态、检查在用药期间或停药后实施，以及既往是否已有GERD证据均应预先规定。

7.2 样本量与模型设定

样本量应根据结局比例、有效参数数量、预期模型拟合度、目标收缩程度和校准精度确定，而不是只依赖简单的“每变量事件数”规则 [45–47]。二维平滑曲面所需自由度高于线性项。实际开发可能需要来自多个中心的数千名参与者，并确保明确阳性和明确阴性病例足以精确评价校准和亚组表现。

候选预测变量、转换方式、交互、先验分布及主要性能指标应在查看结局前写入方案。连续变量保持连续。通过界面设计减少缺失，并采用规范的多重插补，同时对信息性缺失进行敏感性分析 [59,60]。

7.3 拟合与内部验证

采用惩罚极大似然或贝叶斯收缩控制过拟合。Bootstrap内部验证必须覆盖完整建模流程，包括特征选择、平滑参数和校准。如果比较机器学习模型，超参数调节必须嵌套在重抽样内部，否则性能会被高估 [61–65]。随机森林和提升算法可作为比较，但并不会自动优于回归，且可能更难校准 [66]。如果保留非概率模型分值，应评价Platt缩放或等距回归校准，并防止验证结局泄漏到开发过程 [67,68]。

应预先比较以下模型：

1. 现有算术问卷；
2. 将频率与强度分开输入的惩罚逻辑回归；
3. 具有有限交互的单调GAM；
4. 二维IRT与单调GAM组合；
5. 经校准的模糊推理系统；
6. 一个经过严格调参的机器学习基准模型。

8 性能评价与外部验证

区分度不是充分条件。主要指标应包括整体校准、校准斜率、平滑校准曲线、Brier分数、对数损失、预定行动阈值下的敏感度与特异度，以及决策曲线净获益 [26,58,69–72]。曲线下面积只表示排序能力，不能证明报告的70%风险在现实中确实约为70%。重分类指标只能作为次要分析，不能替代可解释的临床变化 [73]。

表 3: BRPI的最低验证框架。

验证阶段	目的	必需证据
表观/内部验证	估计过拟合并调整复杂度	Bootstrap乐观度校正；完整流程重抽样
时间验证	检验时间变化后的性能	新的连续队列；校准与决策曲线
地域验证	检验中心和国家间可迁移性	不同患病率、语言、族群和转诊谱
测量等价性	确保项目在群体间含义相近	项目功能差异及认知访谈
临床效用	判断决策是否改善	净获益、检查使用、重要疾病漏诊及患者负担
影响试验	与常规处理直接比较	个体或整群随机；安全、结局、成本和可接受性
部署后监测	识别漂移与不平等表现	校准监测、亚组审计、版本控制及定期更新

外部验证应同时报告再校准前后的结果。当目标人群患病率改变但预测因子效应相近时，可能只需更新截距；如果症状效应形状发生变化，则需更新系数或曲线。应评价性别、年龄、语言、健康素养、BMI、族群、PPI暴露、糜烂性与非糜烂性疾病及医疗环境等亚组，同时报告样本量和不确定性 [27,74,75]。

9 多分类扩展

二分类GERD标签可能过于粗糙。专科版本可以分别估计：（1）客观病理性反流；（2）反流高敏感；（3）功能性烧心或其他疾病；（4）证据不确定。多项或分层贝叶斯模型可将症状与pH-阻抗指标结合，同时保留不确定性。这反映了症状强度很高但生理酸暴露仍在参考范围内的现实 [3,8,9,76–79]。

多分类模型更适合专科环境，而基层医疗可能更适合三段式二分类输出。两者属于不同预期用途，必须分别验证。不能只依据PPI治疗反应确定标签，因为PPI试验的特异性有限，并可能造成纳入偏倚 [80–82]。

10 跨语言开发与人因设计

该工具应按患者报告结局量表的方法开发，而不是逐字翻译。认知访谈需要评价患者对烧心、酸反流、强度锚点、天数和不确定回答的理解。正向翻译、协调、回译、专家审查和患者测试后，再进行测量等价性分析 [41–44,83,84]。

界面可使用二维症状网格：横向移动表示每周天数，纵向移动表示强度。患者选定点周围的半透明椭圆可表示作答不确定性。这是一种有意义的模糊表示，患者无需假装知道一个精确整数；统计模型对该不确定区域进行积分，而不是将其压缩成虚假精确的分值。

解释应简洁，例如：“您的概率主要受到频繁反流和夜间症状影响；由于本周症状波动，区间较宽。”特征归因方法可辅助解释，但不能证明因果关系，并需检验稳定性 [85]。工具应适合低健康素养者、支持屏幕阅读器，并保留纸质备选版本。

11 偏倚、安全性及报告规范

主要偏倚包括选择偏倚、差异验证、把待评价工具纳入诊断标准、判定者未设盲、参照检查缺失、过拟合、数据泄漏及事后选择阈值。诊断准确性研究应遵循STARD，预测模型报告遵循TRIPOD，并使用QUADAS-2和PROBAST或适用的更新版本评价偏倚 [86–92]。如果自适应或人工智能版本进入前瞻性试验，方案和报告应遵循SPIRIT-AI与CONSORT-AI [93–96]。

临床软件必须保留模型版本、输入单位、适用人群、校准日期、不确定性及审计记录。模型更新应受到治理，不能静默连续改变。输出必须明确概率并不等于疾病证明。任何高风险安全症状均应覆盖模型预测。




图 3: 建议临床流程。BRPI替代症状分诊中的算术加法，但不能覆盖紧急评估或需要客观确诊的情况。

12 建议研究路线

1. 定性开发：通过患者访谈与国际Delphi研究定义症状、锚点、不确定回答和预期用途。
2. 测量学试点：利用重复日记数据估计可靠性、反应分布、维度结构和项目功能差异。

3. **前瞻性诊断开发**：连续入组、参照标准盲法判定，并使用锁定统计方案。
4. **外部验证**：开展时间和地域验证；中文版必须经过文化适配，而非仅由英文逐字翻译。
5. **模型精简**：形成在保持校准与净获益前提下的最短工具，公开系数与透明计算器。
6. **影响试验**：比较BRPI引导与GerDQ、RDQ或常规实践，评价客观检查使用、合理治疗、其他疾病漏诊、症状、成本和患者体验。
7. **持续监测**：评价模型漂移、不良后果、亚组校准及诊断标准变化。

在治理允许时应共享数据和代码，并保护冻结的外部测试集不被反复用于模型调整。“复杂模型没有优于简单逻辑回归”同样是重要结果。只有可重复地改善临床效用，复杂度才具有合理性。

13 讨论

本方法直接回应核心数学问题：频率和强度不能仅因为都被写成小整数就直接相加。它们是不同的测量维度，与疾病之间可能存在非线性和交互。二维概率曲面比一个总和更符合其结构，分级反应模型则尊重患者报告的有序性与不确定性。

模糊逻辑有价值但并不充分。它适合表达模糊边界，也可能使界面更自然；然而，专家规则可能非常确定地给出错误结果。以结局校准的回归、GAM、IRT和贝叶斯不确定性构成更坚实的主要框架。现代机器学习可以比较，但灵活性不等于证据，校准通常比算法新颖性更重要 [45, 46, 48, 49, 63, 66, 69]。

最重要的限制来自目标本身。症状无法完美恢复反流生理，因为GERD具有异质性，症状感知还受到内脏敏感和脑-肠互动影响。因此，BRPI有可能替代粗糙算术问卷，成为更好的分诊和概率工具，但不能负责任地在所有患者中替代内镜或反流监测。其成功标准应是改善决策和患者结局，而不是生成一条看起来复杂的曲线。

14 结论

数学上合理的GERD症状工具应把频率和强度保留为不同维度，依据预先规定的参照标准学习症状特异的非线性关系，报告经校准的概率及不确定性，并将结果连接到明确临床行动。BRPI结合二维分级反应模型、单调贝叶斯广义相加模型、可选模糊作答表示和三区域决策分析。本文方程与图形均为理论示意，不是可直接使用的诊断阈值。在替代现有问卷之前，必须完成前瞻性多中心开发、外部验证、跨语言测量检验及临床影响试验。

声明

伦理审批：本理论方法学文章不适用。 **基金资助**：未声明基金资助。 **利益冲突**：作者应在投稿前披露所有相关利益。 **数据可得性**：本文未生成患者水平数据；示意性系数不得用于临

床诊断。

参考文献

- [1] Vakil N, van Zanten SV, Kahrilas P, Dent J, Jones R. The Montreal definition and classification of gastroesophageal reflux disease: a global evidence-based consensus. *Am J Gastroenterol*. 2006;101:1900–1920. doi:10.1111/j.1572-0241.2006.00630.x.
- [2] Gyawali CP, Kahrilas PJ, Savarino E, et al. Modern diagnosis of GERD: the Lyon Consensus. *Gut*. 2018;67:1351–1362. doi:10.1136/gutjnl-2017-314722.
- [3] Gyawali CP, Yadlapati R, Fass R, et al. Updates to the modern diagnosis of GERD: Lyon Consensus 2.0. *Gut*. 2024;73:361–371. doi:10.1136/gutjnl-2023-330616. PMID:37734911.
- [4] Kahrilas PJ. Gastroesophageal reflux disease. *N Engl J Med*. 2008;359:1700–1707.
- [5] Fass R, Boeckxstaens GE, El-Serag H, Rosen R, Sifrim D, Vaezi MF. Gastro-oesophageal reflux disease. *Nat Rev Dis Primers*. 2021;7:55.
- [6] Katz PO, Dunbar KB, Schnoll-Sussman FH, Greer KB, Yadlapati R, Spechler SJ. ACG clinical guideline for the diagnosis and management of gastroesophageal reflux disease. *Am J Gastroenterol*. 2022;117:27–56. doi:10.14309/ajg.0000000000001538. PMID:34807007.
- [7] Yadlapati R, Gyawali CP, Pandolfino JE, et al. AGA clinical practice update on the diagnosis and management of GERD: expert review. *Clin Gastroenterol Hepatol*. 2022;20:984–994.e1.
- [8] Drossman DA, Hasler WL. Rome IV—functional GI disorders: disorders of gut-brain interaction. *Gastroenterology*. 2016;150:1257–1261.
- [9] Aziz Q, Fass R, Gyawali CP, Miwa H, Pandolfino JE, Zerbib F. Functional esophageal disorders. *Gastroenterology*. 2016;150:1368–1379.
- [10] Roman S, Gyawali CP, Savarino E, et al. Ambulatory reflux monitoring for diagnosis of gastro-esophageal reflux disease: update of the Porto consensus and recommendations from an international consensus group. *Neurogastroenterol Motil*. 2017;29:e13067. PMID:28370768.
- [11] Savarino E, Bredenoord AJ, Fox M, et al. Advances in the physiological assessment and diagnosis of GERD. *Nat Rev Gastroenterol Hepatol*. 2017;14:665–676. PMID:28951582.
- [12] Shaw MJ, Talley NJ, Beebe TJ, et al. Initial validation of a diagnostic questionnaire for gastroesophageal reflux disease. *Am J Gastroenterol*. 2001;96:52–57. doi:10.1111/j.1572-0241.2001.03451.x. PMID:11197287.

- [13] Jones R, Junghard O, Dent J, et al. Development of the GerdQ, a tool for the diagnosis and management of gastro-oesophageal reflux disease in primary care. *Aliment Pharmacol Ther.* 2009;30:1030–1038. PMID:19737151.
- [14] Dent J, Vakil N, Jones R, et al. Accuracy of the diagnosis of GORD by questionnaire, physicians and a trial of proton pump inhibitor treatment: the Diamond Study. *Gut.* 2010;59:714–721. PMID:20551454.
- [15] Jonasson C, Wernersson B, Hoff DAL, Hatlebakk JG. Validation of the GerdQ questionnaire for the diagnosis of gastro-oesophageal reflux disease. *Aliment Pharmacol Ther.* 2013;37:564–572. doi:10.1111/apt.12204.
- [16] Kusano M, Shimoyama Y, Sugimoto S, et al. Development and evaluation of FSSG: frequency scale for the symptoms of GERD. *J Gastroenterol.* 2004;39:888–891.
- [17] Bardhan KD, Stanghellini V, Armstrong D, Berghofer P, Gatz G, Mönnikes H. International validation of ReQuest in patients with endoscopy-negative gastro-oesophageal reflux disease. *Aliment Pharmacol Ther.* 2004;20:891–898.
- [18] Stanghellini V, Armstrong D, Mönnikes H, Bardhan KD. Systematic review: do we need a new gastro-oesophageal reflux disease questionnaire? *Aliment Pharmacol Ther.* 2004;19:463–479.
- [19] Simadibrata DM, Syam AF, Lee YY. Diagnostic accuracy of gastroesophageal reflux disease questionnaire for gastroesophageal reflux disease: a systematic review and meta-analysis. *Neurogastroenterol Motil.* 2023;35:e14619. PMID:37278156.
- [20] Zavala-Gonzales MA, Azamar-Jacome AA, Meixueiro-Daza A, et al. Validation and diagnostic usefulness of gastroesophageal reflux disease questionnaire in a primary care level in Mexico. *J Neurogastroenterol Motil.* 2014;20:475–482. PMID:25273118.
- [21] Locke GR III, Talley NJ, Weaver AL, Zinsmeister AR. A new questionnaire for gastroesophageal reflux disease. *Mayo Clin Proc.* 1994;69:539–547.
- [22] Manterola C, Grande L, Bustos L, Otzen T. Initial validation of a questionnaire for detecting gastroesophageal reflux disease in epidemiological settings. *J Clin Epidemiol.* 2002;55:1041–1045.
- [23] El-Serag HB, Sweet S, Winchester CC, Dent J. Update on the epidemiology of gastro-oesophageal reflux disease: a systematic review. *Gut.* 2014;63:871–880.
- [24] Eusebi LH, Ratnakumaran R, Yuan Y, Solaymani-Dodaran M, Bazzoli F, Ford AC. Global prevalence of, and risk factors for, gastro-oesophageal reflux symptoms: a meta-analysis. *Gut.* 2018;67:430–440.

- [25] Nirwan JS, Hasan SS, Babar ZUD, Conway BR, Ghori MU. Global prevalence and risk factors of gastro-oesophageal reflux disease: systematic review with meta-analysis. *Sci Rep*. 2020;10:5814.
- [26] Pepe MS. *The Statistical Evaluation of Medical Tests for Classification and Prediction*. Oxford: Oxford University Press; 2003.
- [27] Leeflang MMG, Bossuyt PMM, Irwig L. Diagnostic test accuracy may vary with prevalence: implications for evidence-based diagnosis. *J Clin Epidemiol*. 2009;62:5–12.
- [28] Yadlapati R, Kahrilas PJ, Fox MR, et al. Esophageal motility disorders on high-resolution manometry: Chicago classification version 4.0. *Neurogastroenterol Motil*. 2021;33:e14058. doi:10.1111/nmo.14058.
- [29] Lundell LR, Dent J, Bennett JR, et al. Endoscopic assessment of oesophagitis: clinical and functional correlates and further validation of the Los Angeles classification. *Gut*. 1999;45:172–180.
- [30] Sifrim D, Castell D, Dent J, Kahrilas PJ. Gastro-oesophageal reflux monitoring: review and consensus report on detection and definitions of acid, non-acid, and gas reflux. *Gut*. 2004;53:1024–1031.
- [31] Johnson LF, DeMeester TR. Twenty-four-hour pH monitoring of the distal esophagus: a quantitative measure of gastroesophageal reflux. *Am J Gastroenterol*. 1974;62:325–332.
- [32] Jamieson JR, Stein HJ, DeMeester TR, et al. Ambulatory 24-h esophageal pH monitoring: normal values, optimal thresholds, specificity, sensitivity, and reproducibility. *Am J Gastroenterol*. 1992;87:1102–1111.
- [33] Pandolfino JE, Richter JE, Ours T, Guardino JM, Chapman J, Kahrilas PJ. Ambulatory esophageal pH monitoring using a wireless system. *Am J Gastroenterol*. 2003;98:740–749.
- [34] Hasak S, Yadlapati R, Altayar O, et al. Prolonged wireless pH monitoring in patients with persistent reflux symptoms despite proton pump inhibitor therapy. *Clin Gastroenterol Hepatol*. 2020;18:2912–2919.
- [35] Spechler SJ, Souza RF. Barrett’s esophagus. *N Engl J Med*. 2014;371:836–845.
- [36] Samejima F. Estimation of latent ability using a response pattern of graded scores. *Psychometrika Monograph Supplement*. 1969;34:1–97.
- [37] Rasch G. *Probabilistic Models for Some Intelligence and Attainment Tests*. Copenhagen: Danish Institute for Educational Research; 1960.

- [38] Lord FM. *Applications of Item Response Theory to Practical Testing Problems*. Hillsdale: Erlbaum; 1980.
- [39] Embretson SE, Reise SP. *Item Response Theory for Psychologists*. Mahwah: Erlbaum; 2000.
- [40] Reise SP, Waller NG. Item response theory and clinical measurement. *Annu Rev Clin Psychol*. 2009;5:27–48.
- [41] DeVellis RF. *Scale Development: Theory and Applications*. 4th ed. Thousand Oaks: Sage; 2016.
- [42] Streiner DL, Norman GR, Cairney J. *Health Measurement Scales: A Practical Guide to Their Development and Use*. 5th ed. Oxford: Oxford University Press; 2015.
- [43] Mokkink LB, Terwee CB, Patrick DL, et al. The COSMIN study reached international consensus on taxonomy, terminology, and definitions of measurement properties. *J Clin Epidemiol*. 2010;63:737–745.
- [44] Terwee CB, Bot SDM, de Boer MR, et al. Quality criteria were proposed for measurement properties of health status questionnaires. *J Clin Epidemiol*. 2007;60:34–42.
- [45] Harrell FE Jr. *Regression Modeling Strategies*. 2nd ed. Cham: Springer; 2015.
- [46] Steyerberg EW. *Clinical Prediction Models*. 2nd ed. Cham: Springer; 2019.
- [47] Riley RD, Snell KIE, Ensor J, et al. Minimum sample size for developing a multivariable prediction model: Part II—binary and time-to-event outcomes. *Stat Med*. 2019;38:1276–1296.
- [48] Wood SN. *Generalized Additive Models: An Introduction with R*. 2nd ed. Boca Raton: CRC Press; 2017.
- [49] Gelman A, Carlin JB, Stern HS, Dunson DB, Vehtari A, Rubin DB. *Bayesian Data Analysis*. 3rd ed. Boca Raton: CRC Press; 2013.
- [50] McElreath R. *Statistical Rethinking*. 2nd ed. Boca Raton: CRC Press; 2020.
- [51] Zadeh LA. Fuzzy sets. *Information and Control*. 1965;8:338–353. doi:10.1016/S0019-9958(65)90241-X.
- [52] Mamdani EH, Assilian S. An experiment in linguistic synthesis with a fuzzy logic controller. *Int J Man-Mach Stud*. 1975;7:1–13.
- [53] Takagi T, Sugeno M. Fuzzy identification of systems and its applications to modeling and control. *IEEE Trans Syst Man Cybern*. 1985;15:116–132.

- [54] Dubois D, Prade H. *Fuzzy Sets and Systems: Theory and Applications*. New York: Academic Press; 1980.
- [55] Klir GJ, Yuan B. *Fuzzy Sets and Fuzzy Logic: Theory and Applications*. Upper Saddle River: Prentice Hall; 1995.
- [56] Vickers AJ, Elkin EB. Decision curve analysis: a novel method for evaluating prediction models. *Med Decis Making*. 2006;26:565–574.
- [57] Vickers AJ, van Calster B, Steyerberg EW. Net benefit approaches to the evaluation of prediction models, molecular markers, and diagnostic tests. *BMJ*. 2016;352:i6.
- [58] Steyerberg EW, Vickers AJ, Cook NR, et al. Assessing the performance of prediction models: a framework for traditional and novel measures. *Epidemiology*. 2010;21:128–138.
- [59] Rubin DB. *Multiple Imputation for Nonresponse in Surveys*. New York: Wiley; 1987.
- [60] van Buuren S. *Flexible Imputation of Missing Data*. 2nd ed. Boca Raton: CRC Press; 2018.
- [61] Efron B, Tibshirani RJ. *An Introduction to the Bootstrap*. New York: Chapman & Hall; 1993.
- [62] Varma S, Simon R. Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*. 2006;7:91.
- [63] Hastie T, Tibshirani R, Friedman J. *The Elements of Statistical Learning*. 2nd ed. New York: Springer; 2009.
- [64] Breiman L. Random forests. *Mach Learn*. 2001;45:5–32.
- [65] Friedman JH. Greedy function approximation: a gradient boosting machine. *Ann Stat*. 2001;29:1189–1232.
- [66] Christodoulou E, Ma J, Collins GS, Steyerberg EW, Verbakel JY, Van Calster B. A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models. *J Clin Epidemiol*. 2019;110:12–22.
- [67] Platt JC. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In: Smola AJ, Bartlett P, Schölkopf B, Schuurmans D, eds. *Advances in Large Margin Classifiers*. MIT Press; 1999:61–74.
- [68] Zadrozny B, Elkan C. Transforming classifier scores into accurate multiclass probability estimates. In: *Proceedings of KDD*. 2002:694–699.
- [69] Van Calster B, McLernon DJ, van Smeden M, Wynants L, Steyerberg EW. Calibration: the Achilles heel of predictive analytics. *BMC Med*. 2019;17:230.

- [70] Brier GW. Verification of forecasts expressed in terms of probability. *Mon Weather Rev.* 1950;78:1–3.
- [71] Hanley JA, McNeil BJ. The meaning and use of the area under a receiver operating characteristic curve. *Radiology.* 1982;143:29–36.
- [72] DeLong ER, DeLong DM, Clarke-Pearson DL. Comparing the areas under two or more correlated receiver operating characteristic curves. *Biometrics.* 1988;44:837–845.
- [73] Pencina MJ, D’Agostino RB Sr, D’Agostino RB Jr, Vasan RS. Evaluating the added predictive ability of a new marker. *Stat Med.* 2008;27:157–172.
- [74] Debray TPA, Vergouwe Y, Koffijberg H, Nieboer D, Steyerberg EW, Moons KGM. A new framework to enhance the interpretation of external validation studies of clinical prediction models. *J Clin Epidemiol.* 2015;68:279–289.
- [75] Altman DG, Royston P. What do we mean by validating a prognostic model? *Stat Med.* 2000;19:453–473.
- [76] Bredenoord AJ, Weusten BLAM, Curvers WL, Timmer R, Smout AJPM. Determinants of perception of heartburn and regurgitation. *Gut.* 2006;55:313–318.
- [77] Weusten BLAM, Roelofs JMM, Akkermans LMA, Van Berge-Henegouwen GP, Smout AJPM. The symptom-association probability: an improved method for symptom analysis of 24-hour esophageal pH data. *Gastroenterology.* 1994;107:1741–1745.
- [78] Wiener GJ, Richter JE, Copper JB, Wu WC, Castell DO. The symptom index: a clinically important parameter of ambulatory 24-hour esophageal pH monitoring. *Am J Gastroenterol.* 1988;83:358–361.
- [79] Patel A, Wang D, Sainani N, Sayuk GS, Gyawali CP. Distal mean nocturnal baseline impedance on pH-impedance monitoring predicts reflux burden and symptomatic outcome in gastro-oesophageal reflux disease. *Aliment Pharmacol Ther.* 2016;44:890–898.
- [80] Bytzer P, Jones R, Vakil N, et al. Limited ability of the proton-pump inhibitor test to identify patients with gastroesophageal reflux disease. *Clin Gastroenterol Hepatol.* 2012;10:1360–1366.
- [81] Numans ME, Lau J, de Wit NJ, Bonis PA. Short-term treatment with proton-pump inhibitors as a test for gastroesophageal reflux disease: a meta-analysis of diagnostic test characteristics. *Ann Intern Med.* 2004;140:518–527.
- [82] Kahrilas PJ, Howden CW, Hughes N, Molloy-Bland M. Response of regurgitation to proton pump inhibitor therapy in clinical trials of gastroesophageal reflux disease. *Am J Gastroenterol.* 2011;106:1419–1425.

- [83] Cella D, Riley W, Stone A, et al. The Patient-Reported Outcomes Measurement Information System (PROMIS) developed and tested its first wave of adult self-reported health outcome item banks. *J Clin Epidemiol.* 2010;63:1179–1194.
- [84] US Food and Drug Administration. *Guidance for Industry: Patient-Reported Outcome Measures—Use in Medical Product Development to Support Labeling Claims.* Silver Spring, MD: FDA; 2009.
- [85] Lundberg SM, Lee SI. A unified approach to interpreting model predictions. In: *Advances in Neural Information Processing Systems 30.* 2017:4765–4774.
- [86] Collins GS, Reitsma JB, Altman DG, Moons KGM. Transparent reporting of a multivariable prediction model for individual prognosis or diagnosis (TRIPOD). *Ann Intern Med.* 2015;162:55–63.
- [87] Moons KGM, Wolff RF, Riley RD, et al. PROBAST: a tool to assess risk of bias and applicability of prediction model studies. *Ann Intern Med.* 2019;170:51–58.
- [88] Bossuyt PM, Reitsma JB, Bruns DE, et al. STARD 2015: an updated list of essential items for reporting diagnostic accuracy studies. *BMJ.* 2015;351:h5527.
- [89] Whiting PF, Rutjes AWS, Westwood ME, et al. QUADAS-2: a revised tool for the quality assessment of diagnostic accuracy studies. *Ann Intern Med.* 2011;155:529–536.
- [90] McInnes MDF, Moher D, Thombs BD, et al. Preferred reporting items for a systematic review and meta-analysis of diagnostic test accuracy studies: PRISMA-DTA. *JAMA.* 2018;319:388–396.
- [91] Wolff RF, Moons KGM, Riley RD, et al. PROBAST-AI: a tool for assessing risk of bias and applicability of artificial intelligence prediction model studies. *BMJ.* 2025;388:e082505.
- [92] Page MJ, McKenzie JE, Bossuyt PM, et al. The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. *BMJ.* 2021;372:n71.
- [93] Collins GS, Moons KGM. Reporting of artificial intelligence prediction models. *Lancet.* 2019;393:1577–1579.
- [94] Liu X, Rivera SC, Moher D, Calvert MJ, Denniston AK. Reporting guidelines for clinical trial reports for interventions involving artificial intelligence: CONSORT-AI extension. *Nat Med.* 2020;26:1364–1374.
- [95] Cruz Rivera S, Liu X, Chan AW, et al. Guidelines for clinical trial protocols for interventions involving artificial intelligence: SPIRIT-AI extension. *Nat Med.* 2020;26:1351–1363.

- [96] Moher D, Hopewell S, Schulz KF, et al. CONSORT 2010 explanation and elaboration. *BMJ*. 2010;340:c869.